

آمار و احتمال (۲۵۷۳۲)

قضیه حد مرکزی تاناکا

ترم پاییز ۱۴۰۴-۰۵

دانشکده‌ی مهندسی برق

دانشگاه صنعتی شریف

دکتر محمدمهدی مجاهدیان

گراورندگان : بهراد محمدیان، هلیا تاج آبادی،
امیرعلی جهانبخشی، و هانا اخوان



۱ مقدمه

هدف اصلی گزارش نشان دادن مسیر اثبات قضیه حد مرکزی تاناکا است. این قضیه نوع قوی تر از قضیه حد مرکزی ای هست که در کلاس درس نشان داده شده. یک قضیه ی حد مرکزی، نشان میدهد جمع بیشمار متغیر مستقل و هم توزیع به یک متغیر گاوسی میل میکند، فرق قضایای مختلف در نوع این همگرایی است، در کلاس درس همگرایی ضعیف این توزیع ها نشان داده شد، که به نوعی همگرایی توابع توزیع مربوطه است. خواصی از توزیع ها میتوانند طی همگرایی ضعیف همگرا نشوند (مانند گشتاور دوم)، همگرایی واسرشتاین که مورد بحث قضیه تاناکا است نوعی همگرایی قوی تر است. استراتژی کلی به این صورت است که خواص زیر برای فاصله ی اعضای دنباله ی جمع جزیی از توزیع گاوسی نشان داده میشوند:

- نشان داده میشود تابعی فاصله از توزیع گوسی به صورت ضعیف همگرا است.
- فاصله ی جمع دو توزیع با جمع فاصله هایشان برابر است، اگر و فقط اگر هر دو گوسی باشند.
- حد جمع توزیع ها وقتی با خودش جمع میشود برابر خودش خواهد بود.

۲ چارچوب نظریه احتمال

۱.۲ تعاریف اولیه

۱.۱.۲ سیگما جبر

به مجموعه ای (Σ) از زیر مجموعه های یک مجموعه مانند Ω ، یک سیگما جبر روی Ω می گویند اگر خواص زیر را داشته باشد.

$$\emptyset \in \Sigma$$

$$\sigma \in \Sigma \implies \sigma^C \in \Sigma$$

$$\forall i \in \mathbb{N}, \sigma_i \in \Sigma \implies \bigcup_{k=0}^{\infty} \sigma_k \in \Sigma$$

محدودیت خاصیت اخر (بسته بودن تحت اجتماع های شمارا) به شمارا بودن برای جلوگیری از امکان ایجاد مجموعه هایی مانند مجموعه ی ویتالی است. به مشکل وجود این نوع مجموعه ها در نظریه احتمال در بخش های بعد اشاره خواهد شد. همچنین به جفت (Ω, Σ) فضای اندازه پذیر میگوییم.

۲.۱.۲ اندازه

به یک تابع مانند μ از یک سیگما جبر به اعداد حقیقی یک اندازه گفته میشود اگر خواص زیر را داشته باشد.

$$\mu(\sigma) \geq 0$$

$$\mu(\emptyset) = 0$$

$$\sigma_i \cap \sigma_j = \emptyset \quad (i \neq j) \implies \mu(\cup_{k=0}^{\infty} \sigma_k) = \sum_{k=0}^{\infty} \mu(\sigma_k)$$

همچنین به هر اندازه یک احتمال گفته میشود اگر :

$$\mu(\Omega) = 1$$

در آخر، به سه تایی $(\Omega, \Sigma, \mathbb{P})$ که در آن Σ یک سیگما جبر و $\mathbb{P}$ یک احتمال است، یک فضای احتمال گفته میشود.

۳.۱.۲ مجموعه بورل

یک اندازه روی اعداد حقیقی شیفت ناوردا است اگر

$$\mu(A + h) = \mu(A)$$

اندازه μ شیفت ناوردایی که مقدار آن روی بازه 0 ، 1 و 1 است اندازه μ لبگ نامیده میشود (میتوان نشان داد برای بازه ها، معادل همان طول بازه ها است.)، برای تمامی سیگما جبر های ممکن روی اعداد حقیقی نمیتوان اندازه μ لبگ را تعریف کرد. سیگما جبر بسیار معروفی که روی اعداد حقیقی تعریف میشود و اندازه μ لبگ روی آن وجود دارد و یکتا است، مجموعه $\mathcal{B}(\mathbb{R})$ بورل است که با نماد $\mathcal{B}(\mathbb{R})$ نشان داده میشود.

تعریف این مجموعه به شرح زیر است:

$$\mathcal{B}(\mathbb{R}) = \cap \mathcal{F}_i$$

که در آن $\mathcal{F}_i$ تمامی سیگما جبر هایی هستند که شامل مجموعه های باز میشوند. به طور کلی اگر $\mathcal{F}_i$ ها تمامی سیگما جبر های شامل یک مجموعه C دلخواه مانند C باشند، به اشتراک تمامی این سیگما جبر ها (یا کوچک ترین سیگما جبری که شامل C شود) سیگما جبر تولید شده با C و به خود C مولد سیگما جبر میگویند. پس به عبارتی دیگر، مجموعه بورل، سیگما جبر تولید شده با مولد مجموعه های باز اعداد حقیقی است. روش مستقیمی برای نشان کردن تمامی اعضای مجموعه بورل یا حتی نشان کردن مجموعه هایی که شاملشان نیست وجود ندارد. به کمک قضیه هایی میتوان خاصیت هایی که یک اندازه روی مجموعه مولد دارد را به کل سیگما جبر بسط داد.

همانطور که فضاهای برداری میتوانند پایه های مختلفی داشته باشند، یک سیگما جبر میتواند چند مولد داشته باشد.

۴.۱.۲ متغیر تصادفی

یک تابع مانند X از Ω_1 به Ω_2 با سیگما جبر های به ترتیب Σ_1 و Σ_2 اندازه پذیر است، اگر

$$\forall \sigma \in \Sigma_2, \quad X^{-1}(\sigma) \in \Sigma_1$$

یک تابع اندازه پذیر از فضای احتمال دلخواهی به یک فضای اندازه پذیر دیگر متغیر تصادفی نام دارد. (اگر مجموعه مقصد اعداد حقیقی باشد، اصولاً سیگما جبر آن هم مجموعه بورل است.)

اگر X یک متغیر تصادفی روی فضای احتمال $(\Omega, \Sigma, \mathbb{P})$ باشد، به تابع زیر قانون متغیر تصادفی گفته میشود.

$$\text{Law}\{X\}(A) = \mu_X(A) = \mathbb{P}(X^{-1}(A))$$

می توان تحقیق کرد که این تابع خود یک احتمال روی فضای اندازه پذیر اعداد حقیقی و مجموعه بورل است.

۵.۱.۲ امید ریاضی

انتگرال تابع اندازه پذیر و مثبت F تحت اندازه μ به صورت زیر تعریف میشود:

$$\int_{\Omega} F d\mu = \sup [\sum_i (\inf_{A_i} (F)) \mu(A_i)]$$

که در آن A_i ها یک افراز دلخواه از Ω است که داخل سیگما جبر هم باشند.

به صورت شهودی تعریف بالا معادل با این است که مجموعه رو قطعه قطعه بکنیم، مینیمم تابع بر روی هر قطعه را پیدا کرده و در اندازه آن قطعه ضرب کنیم. سپس این کار را برای تمامی افراز های ممکن انجام بدهیم و به صورت حدی ماکسیمم این عبارت را پیدا کنیم. (این کار شباهت زیادی به انتگرال پایین ریمان دارد که در ریاضی ۱ به آن برخوردیم. در واقع اگر اندازه مورد نظر همان اندازه μ لبگ باشد، این انتگرال برای بسیاری از توابع همان انتگرال ریمان است و به آن انتگرال لبگ گفته میشود.) همینطور واضح است که برای فضا های گسسته

این ماکسیمم وقتی اتفاق می افتد که تقسیم هایمان به کوچکترین شکل ممکن، یعنی تک تک اعضا باشد. برای توابعی که منفی هم میشوند، کافی است که دامنه را به زیر مجموعه هایی که تابع در آن مثبت است تقسیم کنیم و اندازه ی انتگرال بخش مثبت را از منفی کم کنیم. امید ریاضی متغیر تصادفی X از فضای احتمال $(\Omega, \Sigma, \mathbb{P})$ به صورت زیر تعریف میشود:

$$\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P}$$

۲.۲ دو قضیه

این دو قضیه کمک خواهند کرد که امید ریاضی متغیرهای تصادفی حدی را (به عنوان مثال متغیر تصادفی مورد بحث در قضیه حد مرکزی) حساب کنیم. (شهودا، حد و امید ریاضی را جا به جا کنیم).

۱.۲.۲ قضیه همگرایی یکنوا

اگر متغیرهای تصادفی مثبت X_n و X را در نظر بگیریم که X_n ها به صورت نقطه نقطه از X کوچک تر هستند و به صورت نقطه به نقطه به آن میل میکنند، قضیه ی همگرایی یکنوا میگوید که امید ریاضی این توابع هم به امید ریاضی X میل میکند. [1] Theorem 4.14. (iii)

۲.۲.۲ قضیه همگرایی تحت سلطه

اگر متغیرهای تصادفی X_n و Y را در نظر بگیریم و به صورت نقطه به نقطه اندازه ی X_n ها از Y کوچک تر باشند. و امید ریاضی Y تعریف بشود (انتگرال حد داشته باشد). آنگاه:

$$X_n \rightarrow X \implies \mathbb{E}X_n \rightarrow \mathbb{E}X$$

[1] Theorem 4.15. (iii)

۳ متریک های احتمال

۱.۳ جفت شدگی ها

یک جفت شدگی از دو احتمال μ_1 و μ_2 یک متغیر تصادفی دوتایی (X_1, X_2) است به صورتی که قانون X_1 و X_2 به ترتیب μ_1 و μ_2 باشد. یا به عبارتی دیگر، جفت شدگی دو توزیع، یک توزیع توام است که توزیع های حاشیه ای آن برابر دو توزیع اصلی هست. جفت شدگی بدیهی دو توزیع، متغیر تصادفی توام (X_1, X_2) است به صورتی که X_1 و X_2 مستقل باشند. مجموعه تمامی جفت شدگی های μ_1 و μ_2 را با

$$\Gamma(\mu_1, \mu_2)$$

نشان میدهند.

۲.۳ فاصله ی واسرشتاین

۱.۲.۳ تعریف

فاصله ی واسرشتاین دو متغیر تصادفی از هر فضای احتمالی به اعداد حقیقی و مجموعه بورل به صورت زیر تعریف میشود:

$$W_p(\mu, \nu) = \inf_{(X,Y) \sim \Gamma(\mu, \nu)} \left(\mathbb{E}[|X - Y|^p]^{\frac{1}{p}} \right)$$

که در اینجا امید ریاضی مطابق با جفت شدگی های مختلف گرفته میشود. اثبات میشود که جفت شدگی بهینه ای وجود دارد اینفیم بالا به ازای آن تحقق پیدا میکند.

[1] 12.4

۳.۳ شهود

یک جفت شدگی مانند (X, Y) روی (μ, ν) در نظر بگیرید. تابع توزیع جفت شدگی را با $f_{(X,Y)}(x, y)$ نشان میدهیم. بنا بر تعریف:

$$f_X(x) = \int f_{(X,Y)}(x, y) dy$$

$$f_Y(y) = \int f_{(X,Y)}(x, y) dx$$

حال فرض کنید می‌خواهیم یک توزیع جرم $f_X(x)$ را به توزیع جرم $f_Y(y)$ تبدیل کنیم. به صورتی که هزینه جا به جا کردن هر واحد جرم به اندازه $|x - y|^p$ باشد. یک برنامه y جا به جایی یک تابع دو متغیره، مثلاً $P(x, y)$ ، است به صورتی که $P(x, y)dxdy$ برابر با مقدار دیفرانسیلی جرم جا به جا شده از نقطه x به نقطه y است. واضحاً اگر قرار باشد توزیع ابتدایی $f_X(x)$ و توزیع نهایی $f_Y(y)$ باشد، کل جرمی که از نقطه x برداشته میشود $f_X(x)$ و کل جرمی که به نقطه y گذاشته میشود $f_Y(y)$ است. بنابراین اگر یک برنامه y جا به جایی قرار باشد این دو توزیع را بهم تبدیل کند باید شرایط زیر برقرار باشد.

$$f_X(x) = \int P_{(X,Y)}(x, y)dy$$

$$f_Y(y) = \int P_{(X,Y)}(x, y)dx$$

با توجه به روابط اول این بخش، واضحاً $f_{(X,Y)}(x, y)$ یک برنامه y جا به جایی از توزیع های حاشیه ایش است. حال اگر بخواهیم هزینه y کل مطابق با یک برنامه y جا به جایی را محاسبه کنیم، کافی است هزینه y مربوط به جا به جایی هر المان جرم را حساب کنیم و در آخر جمع بزنیم. هزینه y ناشی از انتقال جرم از نقطه x به y برابر با $|x - y|^p dxdy$ است. پس هزینه y کل برابر با

$$\int f_{(X,Y)}(x, y) |x - y|^p dxdy$$

است که این همان امید ریاضی محاسبه شده در بخش قبل است. پس فاصله y و استرشتاین دو توزیع برابر با مینیمم هزینه y تبدیل آن ها به هم مطابق با یک تابع هزینه y خاص است.

۴.۳ همگرایی ها

۱.۴.۳ همگرایی ضعیف

همگرایی ضعیف یک دنباله از توزیع ها به یک توزیع تعاریف متنوعی دارد که همگی معادل هم هستند. یکی از این تعاریف مطابق زیر است.

$$\mathbb{E}_n[f] \rightarrow \mathbb{E}[f]$$

به ازای تمامی توابع پیوسته و محدود f . واضح است که اگر اندازه ای به صورت ضعیف، همگرا به یک اندازه شود، تابع مشخصه آن نیز به تابع مشخصه y همان اندازه همگرا میشود. اثبات میشود که برعکس این گزاره نیز درست است و این دو شرط معادل هستند. نکته y مهم دیگر این است که همگرایی ضعیف، همگرایی هیچکدام از گشتاور ها را نتیجه نمیدهد. همچنین چیزی که تحت عنوان قضیه y حد مرکزی در کلاس مطرح شد، درواقع تحت همگرایی ضعیف بود.

۲.۴.۳ همگرایی واسرشتاین

اثبات میشود برای تمامی احتمال ها با گشتاور p محدود، فاصله y واسرشتاین p ام یک متریک است.

[1] Theorem 12.4

متریک تابعی از دو عضو یک مجموعه به اعداد حقیقی مثبت است که متقارن است و در نامساوی مثلث صدق میکند. می گوییم یک دنباله از اندازه ها به یک اندازه تحت متریک واسرشتاین همگرا است اگر:

$$W_p(\mu_n, \mu) \rightarrow 0$$

از این به بعد خودمان را به متریک دوم واسرشتاین محدود میکنیم و در ادامه y این بخش به دو خاصیت همگرایی تحت این متریک میپردازیم.

۵.۳ ارتباط همگرایی ها

می توان نشان داد همگرایی واسرشتاین همگرایی ضعیف را نتیجه میدهد. اثبات این قضیه به صورت کلی به شرح زیر است:

اثبات. می‌خواهیم نشان دهیم برای هر تابع پیوسته و محدود g :

$$\int g f_n(x) dx \rightarrow \int g f(y) dy$$

عبارت بالا معادل است با:

$$\int g(x) f_n(x) dx - \int g(y) f(x) dy \rightarrow 0$$

می توان دو انتگرال بالا را با استفاده از یک جفت شدی روی دو توزیع یکی کرد، پس شرط همگرایی ضعیف معادل است با:

$$\int (g(x) - g(y))f_{(X,Y)}(x,y)dxdy \rightarrow 0$$

می توان نشان داد که برای اینکه $g(x) - g(y)$ بخواهد از یک مقدار دلخواهی بزرگتر باشد، باید $x - y$ از یک مقداری مانند δ بزرگتر باشد (پیوستگی یکنواخت). از طرفی اگر جفت شدگی را همان جفت شدگی بهینه واسرشتاین بگیریم، احتمال آنکه متغیرها در بازه y بالا باشند از مقدار زیر که به صفر میل میکند کمتر است:

$$\int_{|x-y|>\delta} f_{(X,Y)}(x,y)dxdy \leq \frac{1}{\delta^2} \int |x-y|^2 f_{(X,Y)}(x,y)dxdy \rightarrow 0$$

(عبارت دوم دقیقاً همان فاصله واسرشتاین است). پس به صورت کلی، انتگرال روی تمامی بخش هایی که $g(x) - g(y)$ از هر مقدار غیر صفری بیشتر است به صفر میل میکند، پس در کل به صفر میل می کند.

□

در آخر گزارش شرط لازم و کافی برای همگرایی واسرشتاین عنوان میشود.

۴ قضیه اصلی

فاصله ی واسرشتاین یک توزیع، مثلاً μ ، با میانگین صفر و واریانس σ^2 از توزیع $\mathcal{N}(0, \sigma^2)$ را با

$$\mathfrak{e}[\mu]$$

نشان میدهیم.

۱.۴ چند قضیه

قضیه ۱. با کمک این قضیه میتوان فاصله ی واسرشتاین را محاسبه کرد. فرض کنید U یک متغیر تصادفی یکنواخت بین بازه ی 0 و 1 باشد. و $Q_\mu(U)$ متغیر تصادفی از فضای احتمال مربوط به U باشد که قانون آن مساوی با μ است. (به Q تابع چنلک نیز گفته میشود و درواقع همان معکوس تابع توزیع تجمعی است). رابطه ی زیر برقرار است:

$$W_p(\mu_1, \mu_2) = (\mathbb{E}(|Q_{\mu_1}(U) - Q_{\mu_2}(U)|^p))^{\frac{1}{p}} \quad (1)$$

[1] Proposition 12.5.

درواقع توضیح بهینه برای جا به جایی به این صورت است که دو متغیر تصادفی را با استفاده از یک توزیع یکنواخت یکسان به دست بیاوریم. (یعنی تابع توزیع مشترک فقط روی یک منحنی خاص مقدار دارد). همینطور اگر یکی از متغیرها گاوسی باشد، این تنها جفت شدگی ممکن است. ([۲] قضیه اول)

قضیه ۲. اگر X و Y دو متغیر تصادفی و مستقل باشند، رابطه ی زیر برقرار است:

$$\mathfrak{e}[X + Y] < \mathfrak{e}[X] + \mathfrak{e}[Y] \quad (2)$$

مگر هر دو متغیر گاوسی باشند. (به عبارت دیگر $\mathfrak{e}[\cdot]$ نسبت به جمع مستقل محدب است). رابطه کوچکتر مساوی رابطه ی بالا با جاگذاری یک جفت شدگی خاص به دست می آید، با استفاده از رابطه ی ۱ می توان فرم قوی تر را نشان داد.

([۲] قضیه دوم)

قضیه ۳. اگر دنباله ی μ_n ها به μ به صورت ضعیف همگرا شوند و

$$\lim_{A \rightarrow \infty} \sup_n \int_{\|x\| > A} x^2 \mu_n(dx) = 0$$

آنگاه

$$\mathfrak{e}[\mu_n] \rightarrow \mathfrak{e}[\mu] \quad (3)$$

درواقع اگر توزیع به صورت ضعیف حد داشته باشد و انتگرال گشتاور دوم آن مطلقاً همگرا باشد (که در فاصله ی واسرشتاین هم از گشتاور دوم استفاده میشود) آنگاه فاصله ی واسرشتاین از توزیع گاوسی پیوسته است.

([۲] خاصیت "ساده" ی اول)

۲.۴ قضیه حد مرکزی

اگر X_i ها متغیرهای تصادفی مستقل، با توزیع یکسان، میانگین صفر، و واریانس ۱ باشند و

$$\zeta_n = \frac{(X_1 + X_2 + \dots + X_n)}{\sqrt{n}}$$

طبق قضیه حد مرکزی باید:

$$\lim_{n \rightarrow \infty} \mathbf{e}[\zeta_n] = 0 \quad (۴)$$

رابطه ی بالا برای توزیع های با گشتاور چهارم محدود نشان داده میشود:
اگر زیر دنباله

$$\eta_k = \zeta_{2^k}$$

را در نظر بگیریم، واضحاً

$$\eta_{k+1} = \frac{\eta_k + \eta'_k}{\sqrt{2}} \quad (۵)$$

که η' و η مستقل هستند.
با جا گذاری رابطه ی ۵ در رابطه ی ۲، می توان نزولی بودن دنباله ی $\mathbf{e}[\eta_k]$ را نشان داد، و آزانجایی که اعضای دنبال مثبت هستند، دنباله حتماً حد دارد. حد آن را l می نامیم.
طبق نامساوی مارکوف:

$$\mathbb{P}[\|\eta_k\| > A] < \frac{\mathbb{E}[\eta_k^4]}{A^4} \leq \frac{C}{A^4}$$

پس خاصیت رابطه ی ۳ برقرار است. پس اگر حد توزیع η_k را با η نشان بدهیم،

$$l = \mathbf{e}[\eta]$$

از طرفی طبق رابطه ۳

$$\eta = \frac{\eta' + \eta''}{\sqrt{2}}$$

بنابراین

$$\mathbf{e}\left[\frac{\eta + \eta'}{\sqrt{2}}\right] = l$$

پس

$$\mathbf{e}[\eta + \eta'] = 2\mathbf{e}[\eta]$$

و طبق رابطه ی ۲، l صفر است.

از طرفی هر عددی را میتوان به صورت جمعی از توان های دو نوشت. پس:

$$n = \sum a_k 2^k$$

$$\zeta_n = \frac{1}{n} \sum a_k \sqrt{2^k} \eta_k$$

و طبق رابطه ۲

$$\mathbf{e}[\zeta_n] \leq \frac{1}{n} \sum a_k 2^k \mathbf{e}[\eta_k]$$

حد سمت راست صفر است پس سمت چپ هم صفر میشود.

۳.۴ اثبات با مرحله اضافه

در استدلال بخش بالا، قضیه حد مرکزی با فاصله واسرشتاین مستقیماً نشان داده شده است. اگر قضیه حد مرکزی را تحت همگرایی ضعیف فرض بگیریم (که هم در کلاس درس نشان داده شد و هم در منبع [۱]) بنابر رابطه ی ۳، قضیه حدمرکزی برای فاصله ی واسرشتاین ثابت میشود.

۴.۴ قضیه ای کلی تر

می توان نشان داد که شرط لازم و کافی برای همگرایی واسرشتاین، همگرایی ضعیف و همگرایی مطلق گشتاور دوم است.

[3] Theorem 6.9

به صورت شهودی، در همگرایی ضعیف احتمال های بسیار کمی که در فاصله های زیادی از مبدا هستند، در نظر گرفته نمیشوند، ولی همگرایی واسرشتاین اختلاف هایی حداقل از مرتبه ی بزرگی $1/x^2$ را متمایز میکند. با استفاده از این قضیه نیز قضیه حد مرکزی تاناکا واضحاً اثبات میشود.

References

- [1] Lasse Leskelä. *Probability Theory*. Lecture notes, Aalto University. 2024. URL: <https://users.aalto.fi/~leskela/>.
- [2] Hiroshi Tanaka. “An Inequality for a Functional of Probability Distributions and Its Application to Kac’s One-Dimensional Model of a Maxwellian Gas”. In: *The Annals of Probability* 6.2 (1978), pp. 283–292. DOI: 10.1214/aop/1176995535.
- [3] C’edric Villani. *Optimal Transport: Old and New*. Vol. 338. Grundlehren der mathematischen Wissenschaften. Springer, 2009. DOI: 10.1007/978-3-540-71050-9.